


Diagrama de Arquitectura del Sistema

Clínica Vitalis — Ecosistema de Automatización IA para Triage de Urgencias | Entrega Final — Coderhouse

Ecosistema de Automatización IA — Clínica Vitalis (Urgencias)



Referencia de Componentes

Detalle de cada nodo del diagrama y su función dentro del flujo.

Componente	Rol en el sistema
Gmail (Watch emails)	Trigger inteligente. Escucha únicamente correos etiquetados 'Pacientes-Vitalis', evitando procesar notificaciones automáticas ajenas al negocio.
Google Gemini AI	Motor de razonamiento (LLM). Clasifica cada mensaje en prioridad Alta / Media / Baja y extrae motivo, resumen y teléfono del paciente en formato JSON.
Error Handler: Retry	Ruta de resiliencia. Ante fallos temporales de la API (ej. error 503 por alta demanda), reintenta automáticamente hasta 3 veces antes de dejar la ejecución en cola de incompletas.
Airtable — Create a Record	Registra cada mensaje procesado en la tabla URGENCIAS con Estado = 'Procesado por IA', dejando trazabilidad completa sin intervención manual.
Router (Prioridad)	Deriva el flujo según la clasificación de la IA hacia la notificación correspondiente.
Slack (Alta / Baja)	Notificación interna al equipo de la clínica. Para prioridad Alta, funciona como aviso de que un caso espera revisión humana antes de contactar al paciente.
Telegram Bot (Media)	Canal de salida automático hacia el paciente para casos de riesgo menor, sin requerir aprobación humana.
Punto de aprobación humana (HITL)	Para casos de prioridad Alta, una persona del equipo revisa el aviso de Slack y cambia manualmente el Estado del registro a 'Aprobado por Humano' en Airtable.
Airtable — Watch Records	Trigger del Escenario B. Vigila la tabla URGENCIAS y dispara solo cuando Estado = 'Aprobado por Humano'. Esta condición es también el filtro anti-bucle: una vez que el Estado cambia a 'Enviado', el registro deja de cumplir la condición y no vuelve a dispararse.
Telegram Bot (paciente, Alta)	Envía al paciente el mensaje final con instrucciones, únicamente después de la aprobación humana.
Airtable — Update a Record	Cierra el ciclo: actualiza Estado = 'Enviado' y guarda el texto exacto enviado en el campo Respuesta Enviada, como evidencia de la acción ejecutada.
Tabla LOG DE ERRORES	Vinculada a URGENCIAS mediante un campo de enlace (link field), cumpliendo el requisito de relaciones entre tablas para evitar datos aislados.

Manual Operativo de Datos

Esquema de tablas vinculadas y esquemas JSON de transferencia entre integraciones.

1. Esquema de la Base Airtable — 'Urgencias Clinicas Vitalis'

La base contiene 4 tablas. Las dos relevantes para el flujo de Urgencias están vinculadas entre sí mediante un campo de enlace (link field), evitando datos aislados:

Campo	Tipo	Descripción
Nombre/ID paciente	Single line text	Identificador o nombre del paciente/remitente.
Estado	Single select	Pendiente Procesado por IA Aprobado por Humano Rechazado Enviado. Controla el ciclo de vida del registro y actúa como filtro anti-bucle del Escenario B.
Mensaje Original	Long text	Cuerpo completo del email recibido, tal cual.
Aprobado	Checkbox	Marca informativa complementaria del estado de revisión.
Fecha Recepción	Created time	Fecha y hora de creación del registro (formato legible).
Prioridad IA	Single select	alta media baja — clasificación devuelta por Gemini.
Motivo	Long text	Justificación de la clasificación, generada por Gemini.
Última Ejecución	Last modified time	Se actualiza solo ante cambios en Estado, Prioridad IA, Motivo o Aprobado — usada como trigger field del Escenario B.
Canal Contacto	Single line text	Chat ID de Telegram o teléfono del paciente.
Respuesta Enviada	Long text	Texto exacto del mensaje final enviado al paciente (evidencia de ejecución).

Tabla LOG DE ERRORES (vinculada a URGENCIAS):

Campo	Tipo	Descripción
Descripción del Error	Long text	Detalle del error (ej. mensaje de la API).
Tipo de Error	Single select	API Gemini API Telegram Datos Faltantes Otro.
Fecha del Error	Created time	Fecha y hora en que se registró el error.
Registro Urgencia Relacionado	Link to another record → URGENCIAS	Vincula cada error al registro de paciente que lo originó (relación entre tablas).

2. Esquema JSON de Transferencia (Gemini → Make → Airtable)

Google Gemini AI recibe el asunto, remitente y cuerpo del email, y responde únicamente con un objeto JSON plano (sin texto adicional), con el siguiente esquema:

```
{
  "prioridad": "alta | media | baja",
  "motivo": "breve razón de la clasificación",
  "resumen": "resumen de una línea del contenido del correo",
  "telefono_paciente": "número en formato internacional, o null"
}
```

3. Mapeo de Campos entre Etapas

Trazabilidad completa del dato desde que ingresa como email hasta que se envía la respuesta al paciente:

Etapas	Variable / Campo origen	Destino
Gmail (trigger)	Subject, FromName, FullTextBody	Input del prompt enviado a Gemini
Gemini → JSON	prioridad	Airtable → Urgencias.Prioridad IA
Gemini → JSON	motivo	Airtable → Urgencias.Motivo
Gemini → JSON	telefono_paciente	Airtable → Urgencias.Canál Contacto
Gmail	FullTextBody	Airtable → Urgencias.Mensaje Original
Gmail	FromName / From	Airtable → Urgencias.Nombre/ID paciente
Airtable (Escenario B)	Nombre/ID paciente, Motivo	Texto del mensaje de Telegram Bot
Airtable (Escenario B)	Canal Contacto	Telegram Bot → Chat ID destinatario
Telegram Bot → Texto enviado	(mismo texto del mensaje)	Airtable → Urgencias.Respuesta Enviada

Matriz de Optimización de Costos

Justificación del modelo de IA elegido por tipo de tarea, y ahorro estimado frente a alternativas.

Nota: los valores de costo son órdenes de magnitud de referencia pública al momento de diseñar el sistema, sujetos a cambio por cada proveedor. Se incluyen para fundamentar la elección relativa entre modelos, no como cotización exacta.

Tarea	Modelo elegido	Alternativas evaluadas	Justificación	Ahorro estimado
Clasificación de prioridad (triage) — tarea implementada	Google Gemini 3.5 Flash	GPT-4o-mini, Claude Haiku	Tarea simple y de bajo riesgo semántico: clasificar en 3 categorías y extraer 3-4 campos cortos. Un modelo 'flash/mini' de bajo costo es suficiente; usar un modelo premium (GPT-4o, Claude Sonnet) sería sobrecosto sin ganancia de calidad perceptible.	~85-90% más barato que un modelo de gama alta para este mismo volumen de solicitudes.
Lectura clínica densa (ej. interpretar historiales largos o notas médicas extensas) — mejora futura	Claude Sonnet	Gemini Flash, GPT-4o-mini	Para texto largo y con matices clínicos, un modelo de mayor capacidad de razonamiento reduce errores de interpretación; el costo adicional se justifica por el riesgo médico de una mala lectura.	No aplica ahorro — es la tarea donde se invierte más por unidad, a cambio de mayor precisión.
Reprocesamiento masivo (ej. reclasificar un backlog histórico de correos) — mejora futura	Batch API (Gemini Batch)	Llamadas síncronas 1 a 1	Al no requerir respuesta inmediata, procesar en lote aprovecha descuentos por volumen y evita saturar la cuota de la API en horarios pico.	~50% de descuento típico frente al mismo volumen vía API síncrona.

Optimización adicional aplicada: se limitó el Max Tokens de salida del modelo de clasificación al mínimo necesario (un JSON corto de 4 campos), y el trigger de Gmail usa una etiqueta específica ('Pacientes-Vitalis') en vez de escuchar toda la bandeja de entrada, evitando consumo de operaciones innecesarias sobre correos que no son consultas de pacientes.

Documentación de Seguridad y Resiliencia

Minimización de datos, rutas de error y puntos de Human-in-the-loop implementados.

1. Minimización de datos

El sistema solo almacena los campos estrictamente necesarios para operar el triage: mensaje original, clasificación, motivo, canal de contacto y la respuesta enviada. No se solicitan ni guardan datos sensibles adicionales del paciente (historia clínica, DNI, obra social). El trigger de Gmail está acotado a una etiqueta específica ('Pacientes-Vitalis'), de modo que el sistema nunca procesa ni retiene contenido de correos ajenos al proceso de negocio.

2. Rutas de error (Error Handlers)

El módulo de clasificación (Google Gemini AI) cuenta con un Error Handler de tipo **Retry**, configurado con intervalo de 30 segundos y hasta 3 reintentos automáticos. Esta ruta se probó con un fallo real de la API ([503] This model is currently experiencing high demand): el sistema guardó la ejecución en la cola de *Incomplete Executions* en vez de perder el mensaje o romper el escenario completo, permitiendo reintento automático o manual. Esto requirió habilitar 'Store incomplete executions' en la configuración del escenario.

3. Puntos de Human-in-the-loop (HITL)

Para los casos clasificados como prioridad **Alta**, el sistema nunca contacta al paciente de forma automática. En su lugar, notifica al equipo por Slack y detiene el flujo: el registro queda con Estado = 'Procesado por IA' hasta que una persona lo revisa y cambia manualmente el Estado a 'Aprobado por Humano'. Recién entonces, un segundo escenario (disparado por ese cambio de estado) envía las instrucciones al paciente por Telegram. Los casos de prioridad Media y Baja, al ser de menor riesgo, se gestionan de forma automática sin este punto de revisión, priorizando la eficiencia operativa donde el riesgo lo permite.

4. Filtro anti-bucle infinito

El trigger del Escenario B (Airtable Watch Records) filtra únicamente los registros con Estado = 'Aprobado por Humano'. Al procesar un registro, el mismo escenario actualiza su Estado a 'Enviado', lo cual saca a ese registro de la condición del filtro: en la siguiente revisión del trigger, el registro ya no vuelve a dispararse. Esta transición de estado es la protección estructural contra bucles infinitos o reenvíos duplicados.

5. Checklist de seguridad verificado

- ✓ Filtro para evitar bucles infinitos: implementado (ver punto 4).
- ✓ Comparación de tipos de datos correctos en filtros: se corrigió un filtro del Router que comparaba texto contra condiciones duplicadas/vacías; ahora cada rama compara Prioridad (texto) contra un valor de texto único y válido (alta/media/baja).
- ✓ Prompt de IA dinámico con variables del sistema: el prompt de Gemini usa variables del email entrante ({{Subject}}, {{FromName}}, {{FullTextBody}}), sin datos hardcoded.